

ePlace

Nesterov、步长预测与预条件

论文研读笔记 · 第六天 · 学术讲义

第六讲 / 01 | 为什么优化器也很关键

1 每次少算几次目标函数，就可能节省很多时间

前几天建立了 $f = W + \lambda N$ 和它的梯度。现在的问题变成：已知当前坐标和梯度，如何高效产生下一个坐标？论文 §5 比较带线搜索的非线性 CG 与 Nesterov 加步长预测。

非线性 CG 利用上一轮方向 $\mathbf{d}_{k-1}$ ：

$$\mathbf{d}_k = -\mathbf{g}_k + \beta_k \mathbf{d}_{k-1}, \quad \mathbf{g}_k = \nabla f(\mathbf{v}_k). \quad (1)$$

论文 Algorithm 1 使用非负截断的 Polak–Ribière 系数，再用黄金分割搜索选择步长。线搜索要沿同一方向尝试多个候选点，每次都可能需要重新评估线长和密度代价。




图 1 线搜索的代价来自多个候选位置上的重复函数计算。

在论文 ADAPTEC1 的 CG 配置剖析中，线搜索函数评估占 GP 时间约 63.22%，GP 本身占总流程约 79.70%。两者相乘，约为整体时间的 50.39%。这解释了作者为何把求步长作为主要优化对象。

与初始布局里的 CG 区分。 初始 B2B 二次布局求解线性系统时使用的是线性 CG；这里讨论的是非线性目标上的搜索方向与线搜索。名字相同，所解问题与迭代细节不同。

要点 Nesterov 的作用不只是“加入惯性”。在本文中，它与减少线搜索开销的步长预测共同组成求解方案，实验不能只归因于其中一个因素。

文献定位 §5.1、Algorithm 1、§7.3，PDF 第 16–17、30 页。页码对应原论文 PDF。

2 主序列更新，参考序列负责前瞻位置

论文 Algorithm 2 使用主解 $\mathbf{u}_k$ 与参考点 $\mathbf{v}_k$ 。计算梯度的位置是 $\mathbf{v}_k$ 。先暂时忽略预条件，核心更新为

$$\mathbf{u}_{k+1} = \mathbf{v}_k - \alpha_k \nabla f(\mathbf{v}_k), \quad (2)$$

$$a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2}, \quad \beta_k = \frac{a_k - 1}{a_{k+1}}, \quad (3)$$

$$\mathbf{v}_{k+1} = \mathbf{u}_{k+1} + \beta_k(\mathbf{u}_{k+1} - \mathbf{u}_k). \quad (4)$$

a_k 是标量辅助序列， α_k 是步长， β_k 是本页的外推系数；它不是上一页 CG 的同名共轭系数。初始可取 $a_0 = 1$ 、 $\mathbf{u}_0 = \mathbf{v}_0$ 。

按顺序读四个动作

先在参考点算梯度；再做一次下降得到新的主解；然后更新 a 与外推比例；最后沿本轮主解的位移方向再前瞻一点，形成下一轮参考点。




图2 区分“下降得到的点”和“下一次求梯度的参考点”。

当 $a_0 = 1$ 时，第一轮 $\beta_0 = 0$ ，所以 $\mathbf{v}_1 = \mathbf{u}_1$ 。后续外推才逐渐参与。外推可能使目标值短暂升高，不能要求每个参考点的代价都严格单调下降。

要点 本页给出 Algorithm 2 的坐标关系。实际布局还叠加预条件、步长预测和动态参数，因此应先理解更新顺序，再讨论收敛性质。

文献定位 § 5.2、Algorithm 2, PDF 第 17–18 页。页码对应原论文 PDF。

3 梯度变化越快，安全步长通常越小

若梯度满足 Lipschitz 条件，对任意两个位置有

$$\|\nabla f(\mathbf{u}) - \nabla f(\mathbf{v})\| \leq L\|\mathbf{u} - \mathbf{v}\|. \quad (5)$$

L 控制“移动一段距离时，梯度最多变化多快”。在相应光滑条件下，取 $\alpha \leq 1/L$ 可以得到下降保证。论文原文式 (26) 要求

$$f(\mathbf{v}) - f(\mathbf{v} - \alpha \nabla f(\mathbf{v})) \geq \frac{\alpha}{2} \|\nabla f(\mathbf{v})\|^2. \quad (6)$$

完整布局的 L 难以直接得到。论文使用相邻参考点构造原文式 (29):

$$\tilde{L}_k = \frac{\|\nabla f(\mathbf{v}_k) - \nabla f(\mathbf{v}_{k-1})\|}{\|\mathbf{v}_k - \mathbf{v}_{k-1}\|}, \quad \alpha_k \approx \frac{1}{\tilde{L}_k}. \quad (7)$$

已有两轮坐标和梯度即可计算该比值，无需在线搜索中反复计算目标函数。向量差与范数本身仍需要线性工作，不能把整个步长估计说成与实例大小无关的严格常数时间。

数值例子。 两点距离为 0.2，梯度差范数为 1.0，则 $\tilde{L} = 5$ 、预测步长为 0.2。若同样距离下梯度差变为 2.0， $\tilde{L} = 10$ ，预测步长减为 0.1。

估计不是上界证明。 对固定函数，上述两点比值通常只能反映一个局部方向，不保证大于真正的全局 Lipschitz 常数。本文还动态调整 λ 与 γ ，相邻梯度差可能同时包含目标函数变化。因此该规则应视为有效的布局启发式。

实现需处理重复点、极小分母、零梯度差和异常步长。裁剪、回退或下降检查可以作为工程保护，但不能把本讲义建议自动当成论文已实现的步骤。

要点 上传版本初始化段落中 α_0 的比值写法与“步长取 L 的倒数”的文字存在不一致；应按式 (29) 与倒数关系核对实现。

文献定位 § 5.2、式 (26)、(28)–(29)，PDF 第 17–19 页。页码对应原论文 PDF。

4 预条件按对象尺度重新缩放梯度

一个面积很大的宏块，密度力 $q_i \xi_i$ 可能远大于普通单元；连接很多网络的对象也可能累积更大的线长梯度。同一步长作用于所有坐标，容易造成有些对象移动过猛。

论文采用对角近似，原文式 (33) 为

$$D_i = |E_i| + \lambda q_i, \quad \tilde{g}_{ix} = \frac{g_{ix}}{D_i}, \quad \tilde{g}_{iy} = \frac{g_{iy}}{D_i}. \quad (8)$$

E_i 是与对象 i 关联的网络集合， $|E_i|$ 是其网络数。 D_i 是对曲率尺度的工程近似，不是精确 Hessian 对角元，也不是新的目标权重。

教学对象	q_i	$ E_i $	原始梯度 g	g/D_i
小单元	1	2	3	1.000
大宏块	100	2	102	1.000

上表取 $\lambda = 1$ 。两个对象的原始梯度差 34 倍，除以各自尺度后同为 1。这是刻意构造的教学例子，用于说明“补偿尺度”，不是论文实测数据。




图 3 对角缩放缓和不同对象之间的梯度尺度差异。

当 $D_i > 0$ ，方向 $-D^{-1} \nabla f$ 与真实梯度内积为负，因此是局部下降方向。但结合外推和有限步长后，仍不能据此保证每轮目标值下降。filler 的网络数为零，需依赖正的密度项尺度；孤立或退化对象也应注意分母保护。

要点 “电荷大所以力大”与“位移一定大”之间隔着预条件和求解器。论文正是用预条件改善大宏块与小单元混合时的数值行为。

文献定位 § 5.3、式 (30)–(33)，PDF 第 19–20 页。页码对应原论文 PDF。

5 把坐标序列与收敛条件分开理解

取教学函数 $f(u) = u^2$ ，梯度为 $2u$ ，初始 $u_0 = v_0 = 2$ 、 $a_0 = 1$ 。为了观察外推，固定 $\alpha = 0.25$ ；它小于 $1/L = 0.5$ 。不使用布局密度、预条件或动态参数。

k	v_k	$\nabla f(v_k)$	u_{k+1}	β_k	v_{k+1}
0	2.0000	4.0000	1.0000	0.0000	1.0000
1	1.0000	2.0000	0.5000	0.2818	0.3591
2	0.3591	0.7182	0.1796	0.4340	0.0405

以第 2 行为例，先下降到 $u_2 = 1 - 0.25 \times 2 = 0.5$ ；本轮位移为 $u_2 - u_1 = -0.5$ ；再前瞻 $0.2818 \times (-0.5)$ ，得到 $v_2 \approx 0.3591$ 。下一轮梯度应在 0.3591 处计算。

理论条件不能遗漏。 原文 Theorem 5.1 的 $O(1/k^2)$ 目标差界要求固定的凸、光滑函数，梯度 Lipschitz 连续，并满足相应步长条件。完整 ePlace 的密度模型非凸， λ 、 γ 还会变动，论文自己也明确指出定理条件不直接满足。

还应谨慎对待原文将 WA 称为凸函数的概括。第二天的双引脚表达 $W(d) = d \tanh(d/(2\gamma))$ 可以直接检验：令 $z = d/(2\gamma)$ ，则

$$W''(d) = \frac{\operatorname{sech}^2 z}{\gamma} (1 - z \tanh z). \quad (9)$$

当 $z = 2$ 时，括号为负，所以该一维 WA 表达并非全域凸。**光滑不等于凸**，不宜把凸优化理论直接用来证明完整布局的全局最优性。

要点 本论文对求解器的有效性主要由布局实验支持。理解更新公式、理解定理的适用条件、判断实际实验效果，是三项不同的工作。

已掌握：两套坐标、步长估计、对角预条件与理论边界。

下一小步：把前六天拼成完整迭代，再检查论文究竟用什么指标验证收益。

文献定位 § 5.2、Theorem 5.1、§ 5 开头；数值更新与 WA 二阶导数为教学推导。页码对应原论文 PDF。